

資料擷取與匯入

Extracting and Importing Data

Spreadsheet

• 讀取Excel、CSV

```
In [3]: import pandas as pd

# 讀取CSV

df1 = pd.read_csv("Sample.csv",encoding = "big5")

# 讀取Excel: 須事先安裝xlrd (pip install xlrd)

df2 = pd.read_excel("Sample.xlsx",sheetname='sheet1')

In [4]: df1[:5]

Out[4]: year peak_load PRM

記得選擇sheet
```

26.8

29.2

22.1

55.1

48.3

691.8

780.8

851.7

871.6

990.0

72

2 73

3 74

4 75

Notes

▶ 匯出成.CSV

DataFrame.to_csv('name.csv', encoding='big5')



Database

• 範例:MySQL

安裝連接資料庫套件

(e.g. mysql-connector-python, pymongo)

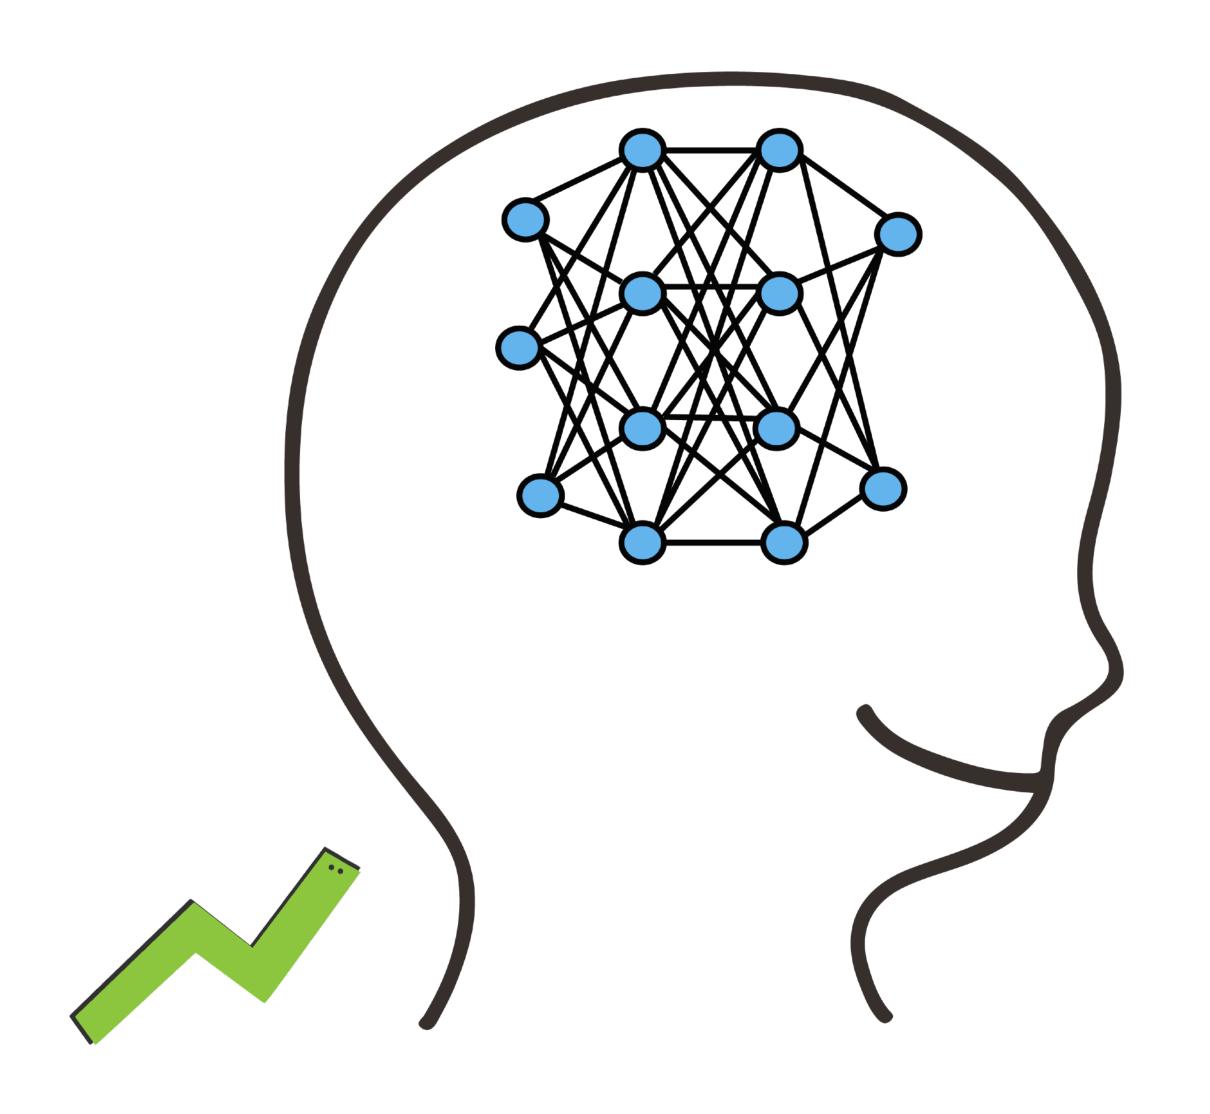
```
import mysql.connector
In [1]:
       import pandas.io.sql as sql
       #連接資料庫
       config = {
           'user': 'sc1387',
                                                連接設定
           'password': '1234',
           'host': '35.201.158.248',
           'database': 'python_ds'
                                                     連接資料庫
       cnx = mysql.connector.connect(**config)
                                                                以SQL指令讀取DB資料
       #readinto dataframe
       df = sql.read_sql('select * from A_LVR_LAND;', cnx)
                                                                    存成DataFrame
       df.head()
```

Out[1]:

	鄉鎮市區	建物移轉總面積平方公尺	建物現況格局-房	建物現況格局-廳	總價元	單價每平方公尺
0	立山區	90.63	3	2	12000000	132406
1	北投區	164.59	5	2	11800000	71693
2	萬華區	34.15	1	1	8200000	240117
3	萬華區	43.40	1	1	9000000	207373
4	萬華區	40.95	0	1	9520000	232479

Notes

▶ ** 是關鍵字引數(Keyword Argument),若想進一步了解, 請參考講義最後的補充內容。

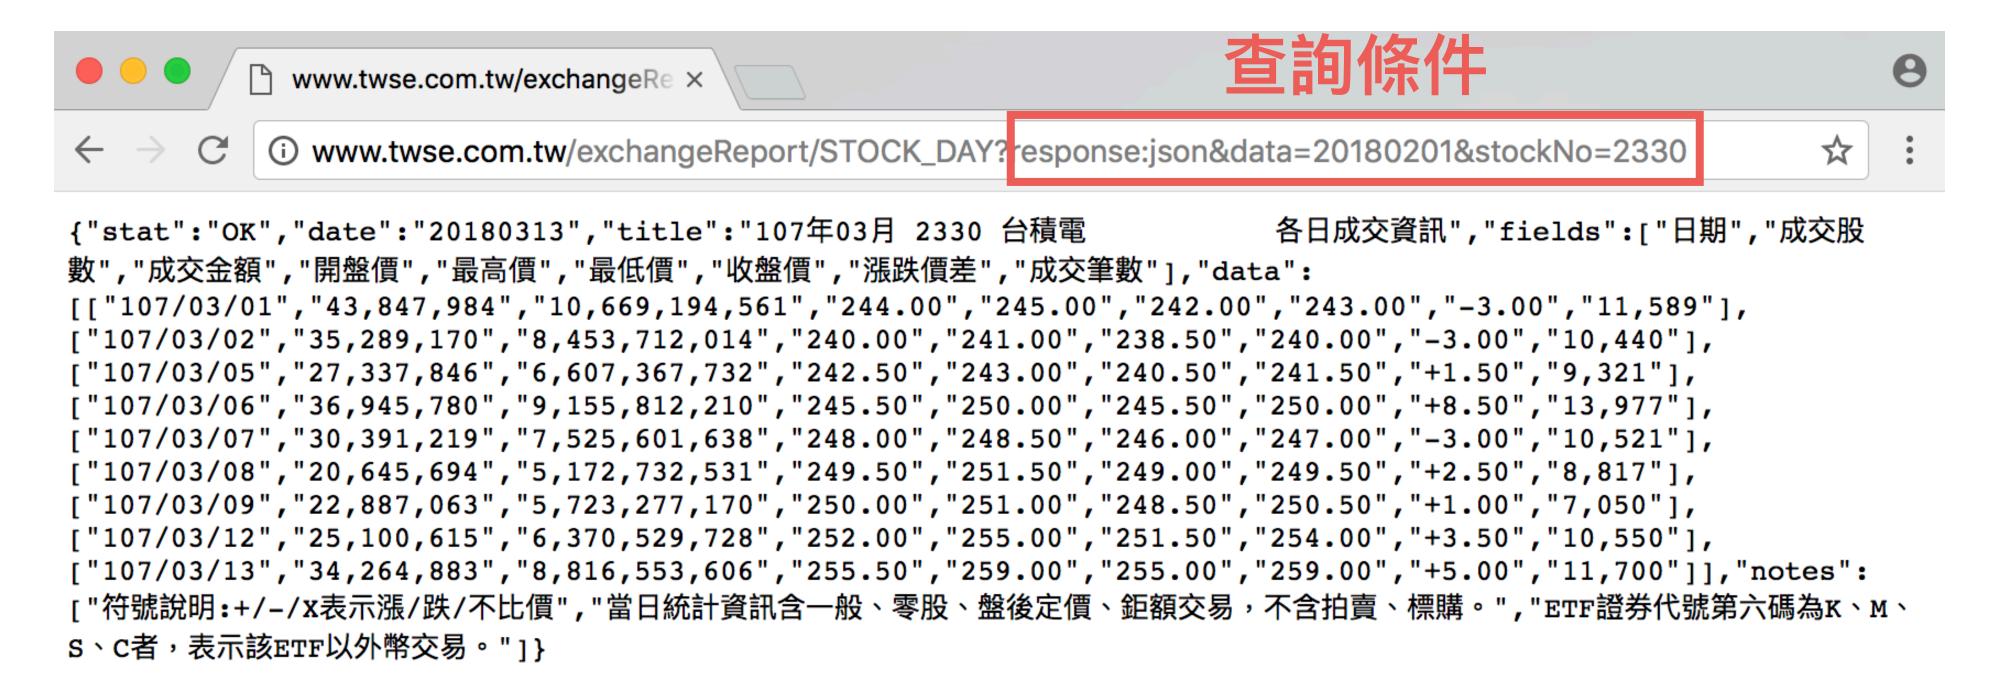


網路爬蟲 Web Crawler

網頁傳值方式

- GET vs. POST
- · GET將參數放在url之後傳遞
 - e.g. https://www.google.com.tw/#q=python (Google搜尋python)
- · POST將參數隱藏起來,安全性較高、網址不變
 - ▶ e.g. 公開資訊觀測站





POST 範例 - 公開資訊觀測站

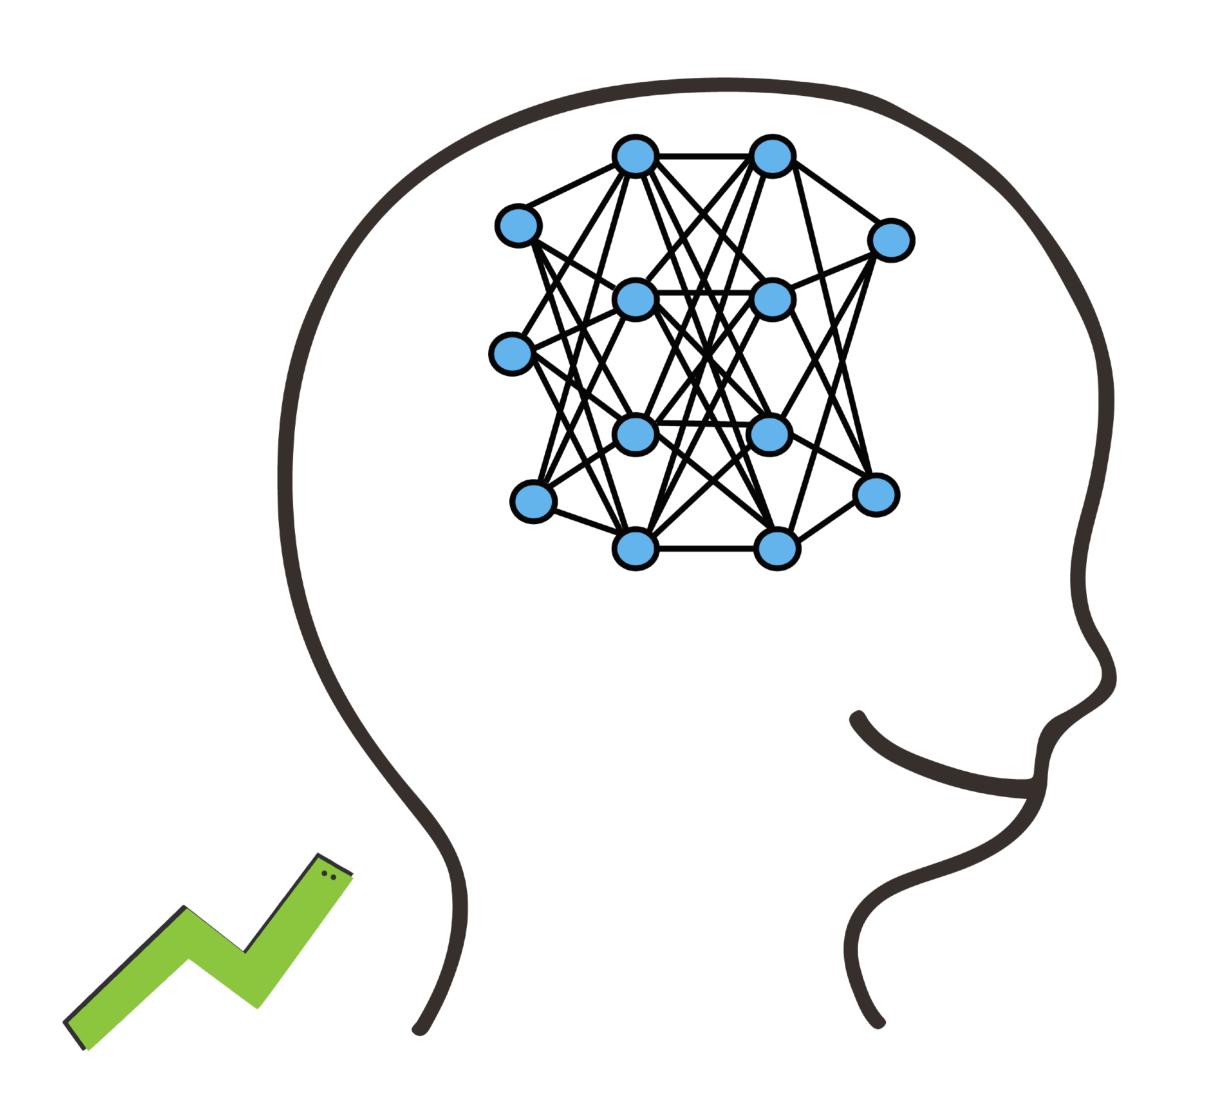


快速抓取網頁中表格

- pd.read_html()
 - · 回傳HTML中所有的表格
 - 回傳格式:DataFrame的list

JSON

- JSON (Javascript Object Notation)
- · 源起於網頁Javascript表示物件的格式,後來變成廣受歡迎的常用資料格式,也是文件儲存的NoSQL資料庫使用的格式(e.g. MongoDB)
- 物件{}、串列[]
 - 範例(wiki):



(optional) HTML剖析-使用BeautifulSoup



- HTML(HyperText Markup Language):超文件標示語言
- · 網頁最基本的語言(常搭配CSS、Javascript等網頁語言)
- tag <> `attribute (e.g. bgcolor)



HTML 剖析

```
<img class="itemcov"
    alt="Python 自動化的樂趣:搞定重複瑣碎&amp;單調無聊的工作"
    data-original="http://iml.book.com.tw/image/getImage?i=http://www.books.com.tw/img/001/073/93/0010739372.jpg&w=85&h=120&v=585a59ac"
    width="85"
    height="120">
```



Python 自動化的樂趣:搞定重複瑣碎&單調無聊的工作

中文書 , Al Sweigart H&C , 基峰 , 出版日期: 2016-12-29

優惠價: **79** 折, **395**元 (放入購物車) 試讀

運用Python寫出程式,幫您在幾分鐘內搞定平常以人工手動處理需要花費數小時的工作。一旦掌握了程式設計的基礎知識,就能輕鬆使用Python編寫程式,把自動化的好用和效率應用在下列這些工作上: ·在一個或多個檔案中搜尋文字 ·建立、更新…… ■ more



HTML 剖析

- html結構:tag、attribute
- 剖析套件: BeautifulSoup4

安裝 beautifulsoup4



轉存為DataFrame

Series to DataFrame

Series1

Series2

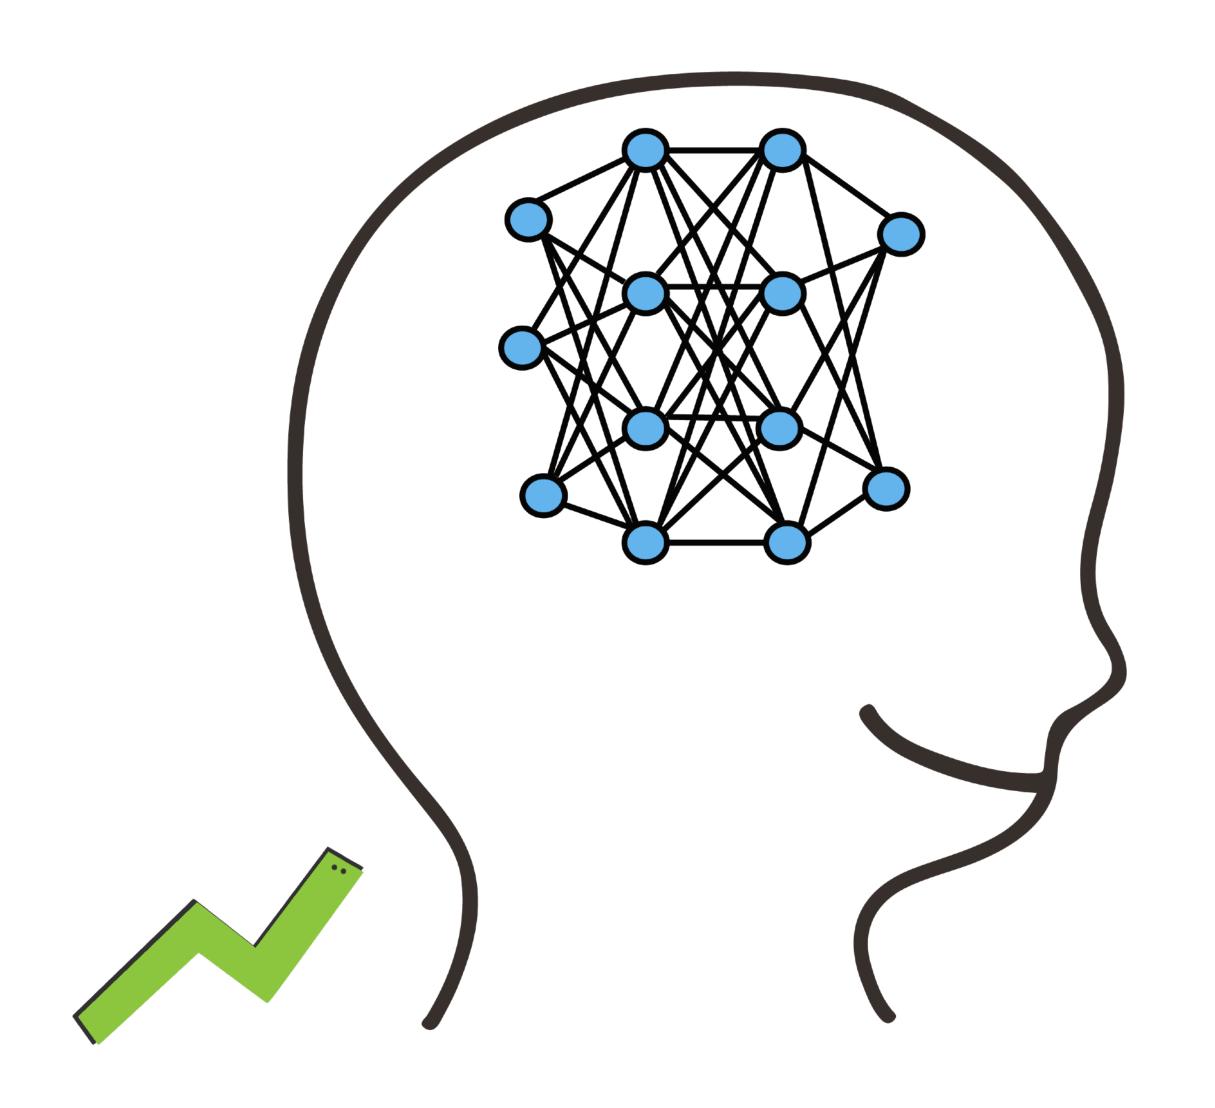


In [122]: #合併成DataFrame

df = pd.DataFrame({'書名':books, '價格': prices}) df[['書名','價格']]

Out[122]:

	書名	價格
0	Python+Spark 2.0+Hadoop機器學習與大數據分析實戰	537
1	網站擷取:使用Python	458
2	Python機器學習	458
3	Data Science from Scratch中文版:用Python學資料科學	458
4	機器學習:使用Python進行預測分析的基本技術	458
5	Python程式設計實務:從初學到活用Python開發技巧的16堂課	442
6	精通 Python:運用簡單的套件進行現代運算	616
7	Think Python: 學習程式設計的思考概念 第二版	411
8	Python程式設計入門指南	411
9	比Hadoop+Python還強:Spark MLlib機器學習實作	432
10	Python 3.5 技術手冊	411
11	不止是測試:Python網路爬蟲王者Selenium	504
12	Python x Arduino物聯網整合開發實戰	387
13	Python 程式設計:從入門到進階應用	466



補充: 函式引數

Function Argument

參數 vs. 引數

- · 參數 (Parameters) :變數名稱
- · 引數 (Arguments) :實際傳入的值

```
參數
In [1]: def hello(name):
    print('Hello ' + name)

In [2]: hello('Andy')
    Hello Andy

引數
```

兩種引數

- 位置引數 (Positional Arguments)
- 關鍵字引數 (Keyword Arguments)

位置引數 (Positional Arguments)

· 根據位置 (argument order matters) 依序將引數傳入函式中的參數

```
In [1]: def hello_all(first, second, third, fourth):
    print('Hello ' + first)
    print('Hello ' + second)
    print('Hello ' + third)
    print('Hello ' + fourth)
In [2]: hello_all('Andy','Ben','Cathy','David')

Hello Andy
Hello Ben
Hello Cathy
Hello David
```

位置引數 (Positional Arguments)

· *可接受傳入任意長度的位置引數,傳入值將視為tuple

```
In [1]: def hello_all(first, *names):
    print('Hello ' + first)
    for name in names: #names is tuple
        print('And Hello ' + name)
In [2]: hello_all('Andy', 'Ben', 'Cathy', 'David')
Hello Andy
And Hello Ben
And Hello Cathy
And Hello David
```

關鍵字引數 (Keyword Arguments)

• 不管引數位置順序,將引數對應到參數名稱輸入函式

```
In [1]: def hello_all(first, second, third, fourth):
    print('Hello ' + first)
    print('Hello ' + second)
    print('Hello ' + third)
    print('Hello ' + fourth)
In [2]: hello_all(third='Andy',first='Ben',fourth='Cathy',second='David')
Hello Ben
Hello David
Hello Andy
Hello Cathy
```

關鍵字引數 (Keyword Arguments)

· **可接受傳入任意長度的關鍵字引數,傳入值將視為dictionary

```
In [1]: def hello_all(**guests):
    for key in guests.keys():
        print('Hello ' + key + ' ' + guests[key])

In [2]: guests={'Andy':'Chen','Ben':'Wang','Cathy':'Lin','David':'Wu'}
    hello_all(**guests)

Hello Ben Wang
    Hello Andy Chen
    Hello David Wu
    Hello Cathy Lin
```