


數據分析方法

Data Analytics Methods



時間序列處理

Time Series Processing



Python 時間資料型態

- time, calendar
- datetime
 - datetime.date : (year, month, day)
 - datetime.time : (hour, minute, second, microsecond)
 - datetime.datetime: (year, month, day, hour, minute, second, microsecond)
 - datetime.timedelta: (days, seconds, microseconds)
- Documents : <https://docs.python.org/3/library/datetime.html>



String & Datetime 轉換

- string to datetime: `datetime.strptime(str, format)`
- datetime to string: `datetime.strftime(datetime, format)`

Directive	Meaning	Example
%a	Weekday as locale's abbreviated name.	So, Mo, ..., Sa (de_DE)
%A	Weekday as locale's full name.	Sonntag, Montag, ..., Samstag (de_DE)
%w	Weekday as a decimal number, where 0 is Sunday and 6 is Saturday.	0, 1, ..., 6
%d	Day of the month as a zero-padded decimal number.	01, 02, ..., 31
%b	Month as locale's abbreviated name.	Jan, Feb, ..., Dez (de_DE)
%B	Month as locale's full name.	Januar, Februar, ..., Dezember (de_DE)
%m	Month as a zero-padded decimal number.	01, 02, ..., 12
%Y	Year with century as a decimal number.	0001, 0002, ..., 2013, 2014, ..., 9999
%H	Hour (24-hour clock) as a zero-padded decimal number.	00, 01, ..., 23
%I	Hour (12-hour clock) as a zero-padded decimal number.	01, 02, ..., 12
%p	Locale's equivalent of either AM or PM.	am, pm (de_DE)
%M	Minute as a zero-padded decimal number.	00, 01, ..., 59
%S	Second as a zero-padded decimal number.	00, 01, ..., 59
%f	Microsecond as a decimal number, zero-padded on the left.	000000, 000001, ..., 999999

- 節錄自：<https://docs.python.org/3/library/datetime.html>



Pandas DatetimeIndex

- 把DataFrame的index轉為DatetimeIndex型態

- e.g `df.index = pd.to_datetime(df.index,format='%Y-%m-%d')`

- DatetimeIndex 時間分割/聚合


- e.g. `DataFrame.groupby([columns]).agg_func()`

- e.g. `DataFrame.resample('M').agg_func()`

- e.g. `DataFrame.resample('Q-NOV').agg_func()` #Q-EndMonth

- Document (DatetimeIndex的attributes、methods) : <http://pandas.pydata.org/pandas-docs/stable/generated/pandas.DatetimeIndex.html>

M	1	2	3	4	5	6	7	8	9	10	11	12
Q-DEC	Q1			Q2			Q3			Q4		
Q-NOV	Q1		Q2			Q3			Q4		Q1	



統計分析

Statistical Analysis



描述性統計 (Descriptive Statistics)

- 或稱「敘述性統計」
- 集中量數：呈現資料集中的情形，如：(算術)平均、中位數、眾數等
- 變異量數：呈現資料分散的情形，如：全距（最大值 - 最小值）、標準差、四分位數等

‣ DataFrame.describe()

	A	B	C	D
count	6.000000	6.000000	6.000000	6.000000
mean	0.473862	0.615370	0.568419	0.622193
std	0.252262	0.312380	0.164988	0.329959
min	0.080301	0.202910	0.317583	0.047279
25%	0.361322	0.365285	0.462811	0.507737
50%	0.474192	0.685850	0.660573	0.725291
75%	0.684415	0.851957	0.677213	0.809227
max	0.736302	0.951857	0.692137	0.962875

幾何平均數 (Geometric Mean)

- 適用於計算比率數據的變化率

$$G = \sqrt[n]{\prod_{i=1}^n x_i} = \sqrt[n]{x_1 \cdot x_2 \cdots x_n}$$

- e.g. 營業額成長：12%, 15%, -4%, -10%, 6%
- `scipy.stats.gmean([1.12, 1.15, 0.96, 0.9, 1.06]) => 1.04 (4%)`

調和平均數 (Harmonic Mean)

- 數值倒數的算術平均數的倒數，又稱為「倒數平均數」。

$$H = \frac{n}{\frac{1}{x_1} + \frac{1}{x_2} + \dots + \frac{1}{x_n}}$$

- e.g. 台北到高雄坐高鐵平均時速300公里、高雄到台北坐台鐵普悠瑪號平均時速150公里，全程平均時速是多少？
- `scipy.stats.hmean([300, 150]) => 200`



截尾平均數 (Trimmed Mean)

- 平均數容易受到極端值影響
- 截尾平均數會將極端值去除後再取算術平均
 - 自訂上下限： `scipy.stats.tmean(array-like data, (lower limit, upper limit))`
 - 截尾後的標準差 (tstd) 、變異數 (tvar) 、最大值 (tmax) 、最小值 (tmin)
 - 依比例去除： `scipy.stats.trim_mean(array-like data, proportiontocut)`



四分位數 (Quartile)

- 將數據從小到大排列
 - 第一四分位數 (Q_1) : 在 $1/4$ 位置的數，又稱「較小四分位數」
 - 第二四分位數 (Q_2) : 在 $1/2$ 位置的數，又稱「中位數」
 - 第三四分位數 (Q_3) : 在 $3/4$ 位置的數，又稱「較大四分位數」
 - 四分位距 (IQR) = $Q_3 - Q_1$
 - e.g. 1, 2, 3, 4, 5, 6, 7, 8
 - 內插法 : $Q_1 = 2.75$ 、 $Q_2 = 4.5$ 、 $Q_3 = 6.25$

Notes

► 四分位數的計算方法爭議

四分位數確切的數值計算方法仍具爭議
Scipy和Pandas計算出的值有少許誤差。



基本統計函式表



統計函式		Pandas DataFrame	Scipy.stats	Numpy
敘述統計		DataFrame.describe()	describe(<i>data</i>)	x
算術	平均數	DataFrame.mean()	x	mean(<i>data</i>)
幾何		x	gmean(<i>data</i>)	x
調和		x	hmean(<i>data</i>)	x
截尾		x	trim_mean(<i>data</i> , <i>proportiontocut</i>) tmean(<i>data</i> , (<i>lower limit</i> , <i>upper limit</i>))	x
加權		x	x	average(<i>data</i> , <i>weights</i>)
截尾	最大值	x	tmax(<i>data</i> , (<i>lower limit</i> , <i>upper limit</i>))	x
	最小值	x	tmin(<i>data</i> , (<i>lower limit</i> , <i>upper limit</i>))	x
	標準差	x	tstd(<i>data</i> , (<i>lower limit</i> , <i>upper limit</i>))	x
	變異數	x	tvar(<i>data</i> , (<i>lower limit</i> , <i>upper limit</i>))	x
最大值		DataFrame.max()	x	max(<i>data</i>)
最小值		DataFrame.min()	x	min(<i>data</i>)
中位數		DataFrame.median()	x	median(<i>data</i>)
標準差		DataFrame.std()	x	std(<i>data</i>)
變異數		DataFrame.var()	x	var(<i>data</i>)
四分位數		DataFrame.quantile(<i>quantile</i>)	mstats.mquantiles(<i>data</i>)	x
眾數		DataFrame.mode() (0.19.1版)	mode(<i>data</i>) 12 (0.18.1版)	x (1.11版)







機率分佈

- 連續機率分佈 (Continuous Distributions) :

- 伽瑪分佈 (Gamma Distribution)
- 指數分佈 (Exponential Distribution)
- 常態分佈 (Normal Distribution)
- 均勻分佈 (Uniform Distribution)
- 卡方分佈 (Chi-square Distribution)

- 間斷機率分佈 (Discrete Distributions) :

- 白努力分佈 (Bernoulli Distribution)
- 二項式分佈 (Binomial Distribution)
- 負二項式分佈 (Negative Binomial Distribution)
- 波式分佈 (Poisson Distribution)
- 超幾何分佈 (Hypergeometric Distribution)





Scipy.stats

- Scipy 統計函式：<https://docs.scipy.org/doc/scipy/reference/stats.html>

Continuous distributions

<code>alpha</code>	An alpha continuous random variable.
<code>anglit</code>	An anglit continuous random variable.
<code>arcsine</code>	An arcsine continuous random variable.
<code>beta</code>	A beta continuous random variable.
<code>betaprime</code>	A beta prime continuous random variable.
<code>bradford</code>	A Bradford continuous random variable.
<code>burr</code>	A Burr (Type III) continuous random variable.
<code>burr12</code>	A Burr (Type XII) continuous random variable.
<code>cauchy</code>	A Cauchy continuous random variable.
<code>chi</code>	A chi continuous random variable.
<code>chi2</code>	A chi-squared continuous random variable.
<code>cosine</code>	A cosine continuous random variable.
<code>dgamma</code>	A double gamma continuous random variable.
<code>dweibull</code>	A double Weibull continuous random variable.
<code>erlang</code>	An Erlang continuous random variable.
<code>expon</code>	An exponential continuous random variable.

Discrete distributions

<code>bernoulli</code>	A Bernoulli discrete random variable.
<code>binom</code>	A binomial discrete random variable.
<code>boltzmann</code>	A Boltzmann (Truncated Discrete Exponential) random variable.
<code>dlaplace</code>	A Laplacian discrete random variable.
<code>geom</code>	A geometric discrete random variable.
<code>hypergeom</code>	A hypergeometric discrete random variable.
<code>logser</code>	A Logarithmic (Log-Series, Series) discrete random variable.
<code>nbinom</code>	A negative binomial discrete random variable.
<code>planck</code>	A Planck discrete exponential random variable.
<code>poisson</code>	A Poisson discrete random variable.
<code>randint</code>	A uniform discrete random variable.
<code>skellam</code>	A Skellam discrete random variable.
<code>zipf</code>	A Zipf discrete random variable.




其他常用統計函式

- One-way ANOVA
- F value
- T-test
- 相關性 (Correlation)
- 峰度 (kurtosis)
- 偏態 (skewness)
- 共變數 (Covariance)
- ...



References

- Numpy 統計関式 : <https://docs.scipy.org/doc/numpy/reference/routines.statistics.html>
- Scipy 統計関式 : <https://docs.scipy.org/doc/scipy/reference/stats.html>
- Pandas DataFrame 統計関式 : <http://pandas.pydata.org/pandas-docs/stable/api.html#api-dataframe-stats>




異常値偵測

Anomaly Detection




異常值偵測(1) - 四分位數與箱形圖



`plt.boxplot(x, showfliers=True)`

- 四分位間距(InterQuartile Range, IQR)
 - $Q_3 - Q_1$
- 最大值： $Q_3 + 1.5 * IQR$
- 最小值： $Q_1 - 1.5 * IQR$
- 異常值：高於最大值、低於最小值

異常值偵測(2) - 常態分佈與標準差



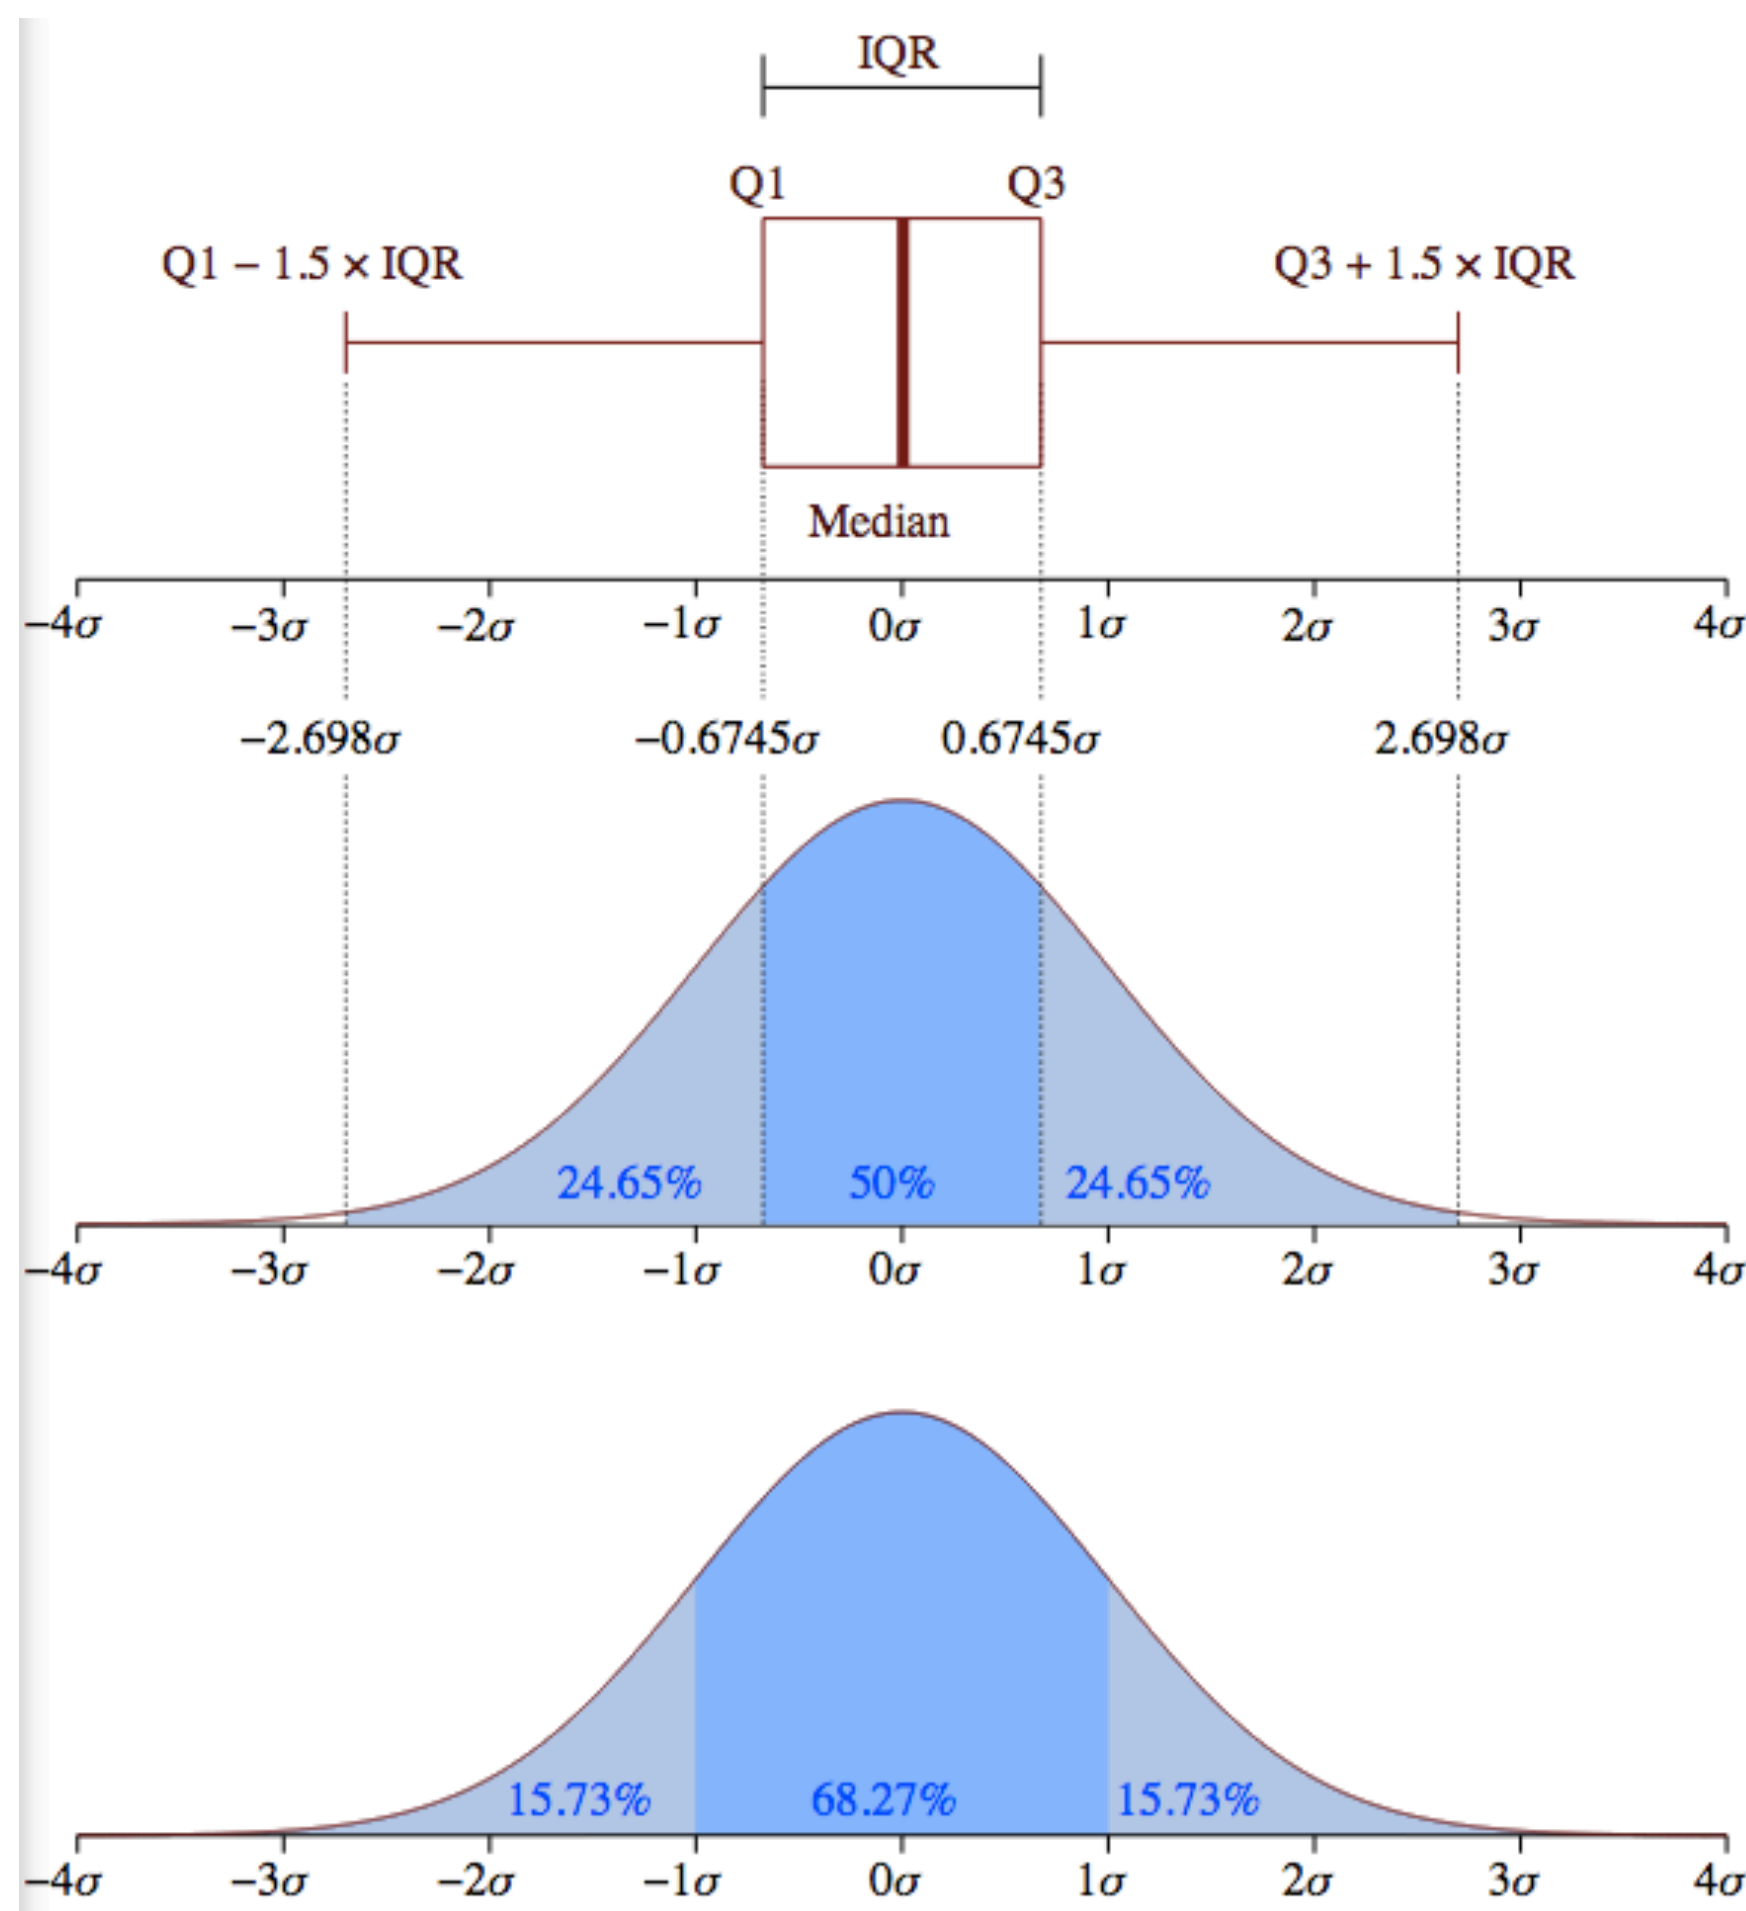
`df.plot(kind='kde')`


- 平均 (mean) 、標準差 (std, σ)
- 上限： $\text{mean} + 3 * \sigma$ (sigma)
- 下限： $\text{mean} - 3 * \sigma$ (sigma)
- 異常值：高於上限、低於下限



比較

- 若資料型態傾向常態分佈（例如：身高、體重、成績），適合使用標準差的判定方式
- 若異常值過大或過小，容易過度影響標準差，則建議使用四分位數和箱型圖，因為大於 Q_3 和小於 Q_1 的值不論離多遠都不會影響四分位數的值，所以在判定異常值效果好





相關性分析

Correlation Analysis

Pearson 相關係數

- 最常用的相關係數 (-1~+1)

$$\rho_{X,Y} = \frac{\overset{\substack{\text{共變數} \\ \downarrow}}{\text{cov}(X, Y)}}{\underset{\substack{\uparrow \\ \text{標準差}}}{\sigma_X \sigma_Y}} = \frac{E[(X - \mu_X)(Y - \mu_Y)]}{\sigma_X \sigma_Y}$$

$$r = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum_{i=1}^n (X_i - \bar{X})^2} \sqrt{\sum_{i=1}^n (Y_i - \bar{Y})^2}}$$


(Pearson, 1917)



相關程度

- 相關程度



- ▶ $+1$: 完全正相關
- ▶ -1 : 完全負相關
- ▶ 0.3 至 -0.3 : 低度 (正/負)相關
- ▶ $(+/-) 0.3$ 至 0.6 : 中度 (正/負)相關
- ▶ $(+/-) 0.6$ 至 0.9 : 高度 (正/負)相關
 - ▶ `DataFrame.corr()`




(from wikipedia)



相關程度不等於有因果



(<http://tylervigen.com/>)




主次因素分析

Pareto Analysis


80/20 法則

- 又稱為「Pareto 法則」
- 義大利經濟學家Pareto(1906) 觀察到，當時義大利
- 80%（多數）的結果來自於20%（少數）的原因
 - e.g. 80%的收益來自20%的產品
- Pareto Chart (柏拉圖、主次因素分析)




長尾理論 (Long-tail)

- Chris Anderson (2004)：非熱門的商品(80%)加起來的銷售量超過熱門商品(20%)
- 網路上的情況（如電子商務）更為明顯
- 改變80/20法則的思維



- ▶ e.g. Amazon 57%的銷售來自非熱門商品





References

- Chris A. (October, 2004) The Long Tail. Wired. Retrieved from: <https://www.wired.com/2004/10/tail/>
- Chris A. The Long Tail, in a nutshell. Retrieved from: <http://www.thelongtail.com/about.html>
- Neil, P. (2015, December 22). 7 Brilliant Examples of Brands Driving Long-Tail Organic Traffic. Retrieved from: <http://neilpatel.com/2015/12/22/7-brilliant-examples-of-brands-driving-long-tail-organic-traffic/>